

JOURNAL DE BORD

Cryptographie : collisions de md5

Projet intégratif Sujet 1

SAE 204

Séance 1	1
Séance 2	2
Séance 3	3
Séance 4	4
Séance 5	5
Séance 6	6
Séance 7	8
Séance 8	9
Séance 9	10

Séance 1

DATE : 12/05/2026 --- **Heure :** 12h18 --- **Séance :** 1

Étudiant présent : LACOSTE Nathan

Travail réalisé : Recherche et documentation

// J'espère que vous savez bien parler anglais car beaucoup des documents que j'ai consulté sont en anglais.

Découverte Hachage / md5 :

- https://www.youtube.com/watch?v=R_mOWu3s6y4 (Anglais)
- <https://www.youtube.com/watch?v=5MiMK45gkTY&t=53s> (Anglais)
- <https://www.youtube.com/watch?v=jSpEPpQlD10> (Français)
- https://fr.wikipedia.org/wiki/Fonction_de_hachage_cryptographique (Français)
- <https://www.okta.com/fr-fr/identity-101/md5/> (Français)

Papier de recherche (thèse) :

- <https://marc-stevens.nl/research/hashclash/On%20Collisions%20for%20MD5%20-%20M.M.J.%20Stevens.pdf> (Anglais)

Découverte CUDA :

- <https://www.youtube.com/watch?v=pPStdjuYzSI> (Anglais)
- https://fr.wikipedia.org/wiki/Compute_Unified_Device_Architecture (Français)
- <https://www.youtube.com/watch?v=r9lqwpMR9TE> (Anglais)

Documentation C++ :

- <https://www.w3schools.com/CPP/default.asp> (Anglais)
- Code Giraphe *// Code du projet des Olympiade de l'ingé que je bidouille pour pas trop perdre la main en C++*

Séance 2

DATE : 12/05/2026 --- Heure : 17h38 --- Séance : 2

Étudiant présent : LACOSTE Nathan

Travail réalisé : Entraînement code C++

// lien vers site utilisé pour les exercices :

// https://fr.wikibooks.org/wiki/Exercices_en_langage_C%2B%2B/Notions_de_base

Exercice réaliser :

- Exercice 1

```
Hello world !
ce code utilise cout pour afficher des trucs

=== Code Execution Successful ===
```

- Exercice 2

```
#include <iostream>
using namespace std;

int main() {
    // Write C++ code here
    int longueur;
    int largeur;
    string choix;

    cout << "longueur du champs (en mètres) : ";
    cin >> longueur;
    cout << "largeur du champs (en mètres) : ";
    cin >> largeur;
    cout << "a : périmètre b : surface\n" << "votre choix : ";
    cin >> choix;

    if (choix == "a") {
        int perimetre = (largeur + longueur)*2;
        cout << "périmètre du champs : " << perimetre << " mètres";
    }
    else {
        int surface = largeur * longueur;
        cout << "surface du champs : " << surface << " mètres carrés";
        return 0;
    }
}
```

longueur du champs (en mètres) : 10
 largeur du champs (en mètres) : 15
 a : périmètre b : surface
 votre choix : b
 surface du champs : 150 mètres carrés

=== Code Execution Successful ===

- Exercice 3

```
1 // Online C++ compiler to run C++ program online
2 #include <iostream>
3 using namespace std;
4
5 int main() {
6     // Write C++ code here
7     int num;
8     double somme = 0 ;
9     int oly;
10
11     cout << "Nombre de notes : ";
12     cin >> oly;
13     cout << "\nInsérer les numéros un à un :\n";
14     for (int ayo = 1; ayo <= oly; ayo++) {
15         cout << "note " << ayo << " : ";
16         cin >> num; somme = somme + num;
17     }
18
19     double moy = somme / oly;
20     cout << "la moyenne est : " << moy;
21     return 0;
22 }
```

Nombre de notes : 7

Insérer les numéros un à un :

note 1 : 15
 note 2 : 20
 note 3 : 16
 note 4 : 18
 note 5 : 14
 note 6 : 17
 note 7 : 13
 la moyenne est : 16.1429

=== Code Execution Successful ===

Séance 3

DATE : 20/05/2026 --- **Heure :** 17h41 --- **Séance :** 3

Étudiant présent : LACOSTE Nathan BELHARET ADAM

Travail réalisé : Galère


Nous avons tout essayé pour faire marcher cette carte graphique.

Nous avons d'abord tenté d'installer VSCode sur l'ordinateur de Nathan (aka mon ordi), mais l'éditeur était beaucoup trop complexe à prendre en main, avec des documentations compliquer.

Finalement après pas mal de recherche la doc nous a renvoyer vers Visual Studio. Que nous avons donc installé, cet IDE était plus facile à comprendre cependant un autre problème as vite émerger.

Mon ordinateur ainsi que le poste présent dans la salle ne détectaient pas la carte graphique, nous avons donc fait encore plus de recherche pour trouver une solution. Solution que nous pensions avoir trouver quand un site nous disait qu'il s'agissait d'un problème de drivers. Nous avons donc téléchargé les drivers nécessaire, mais la carte n'étant pas détecter par les ordis, impossible pour les drivers de s'installer.

Après cet n-ième échec, nous avons donc décider de demander à Chatgpt quel était le problème et il s'avère que mon ordi n'est pas compatible Thunderbolt, et que pour le poste présent dans la salle, c'est un problème lié au porte PCIE.



Nom	Modifié le	Type	Taille
Aujourd'hui			
VisualStudioSetup	20/05/2026 15:22	Application	5 563 Ko
cuda_13.2.1_windows	20/05/2026 14:22	Application	2 438 518 Ko
596.49-desktop-win10-win11-64bit-inter...	20/05/2026 16:39	Application	936 340 Ko
VSCodeUserSetup-x64-1.121.0	20/05/2026 14:35	Application	163 422 Ko

//Copie d'écran de mes téléchargements afin que vous ayez une idée du temps que nous avons passé à galérer avant de céder de demander à chatgpt.

Séance 4

DATE : 20/05/2026 --- **Heure :** 11h58 --- **Séance :** 4

Étudiant présent : LACOSTE Nathan BELHARET ADAM

Travail réalisé : Codage

VICTOIRE !! Adam a réussi à faire marcher la carte graphique. Le problème était simple : le port de mon ordi n'est pas du thunderbolt donc la carte graphique n'était pas reconnue. *//un problème si simple nous a coûté une après-midi entière T-T*

Après avoir branché sur un ordinateur de l'ut (qui a donc un port thunderbolt), la carte graphique était bien reconnue.

Nous avons dû procéder à l'installation des différents logiciels/drivers pour le bon procédé du projet.

Voici la liste des logiciels/drivers téléchargés :

- Studio Code Community 2022
- Cuda ToolKit 12.9
- Drivers de la carte graphique

Suite à cela, nous avons créé un nouveau projet sur Studio Code que l'on a nommé MD5-PROJET.

Séance 5

DATE : 29/05/2026 --- **Heure :** 16h59 --- **Séance :** 5


Étudiant présent : LACOSTE Nathan BELHARET ADAM

Travail réalisé : codage collision (64 bits) + recherches infos

Il faut savoir qu'il n'existe pas de bibliothèque md5 sur cuda, c'est à dire qu'on peut pas faire md5("message") et recevoir comme par magie le haché de ce "message". Il faut donc implémenter MD5 en GPU. Après des recherches Nathan a trouvé sur Wikipedia un code partiel de md5 en C++, chose qui nous a bien aidé car c'est la chose qui aurait prit le plus de temps.

Le reste du code est dédié aux attributions des thread, chaque thread aura un hash à calculer, à la gestion de la ram, car après que le hash soit calculé, ce dernier est envoyé au CPU et stocké dans la RAM pour ensuite comparé les différents hash qu'il a stocké et chercher si une collision a été trouver.

Par brute force nous avons réussi à trouver une collision pour maximum 52 bits, à voir si une collision entre 2 messages est possible sur 64 bits en brute force si nous le laissons tourner plusieurs heures d'affiler.



```
Collision MD5 sur 52 bits
.....
COLLISION TROUVEE !
hash = 10af666819adf
msg1 = 82356261
msg2 = 93650469

C:\Users\etudiants\source\repos\MD5\x64\Debug\MD5.exe (processus 10532) s'est terminé avec le code 0 (0x0).
Appuyez sur une touche pour fermer cette fenêtre. . .|
```

Pour continuer, nous avons fait des recherches pour trouver une méthode de collision sur les 128 bits, que nous détaillerons à la prochaine séance.

Pour finir nous avons commencé à travailler sur un code de reverse md5 par dictionnaire, c'est à dire que nous entrons le hash d'un mot de passe. Et notre code regarde dans un dictionnaire (dans notre cas c'est un dictionnaire trouvé sur GitHub issu d'une fuite de donnée de 2009 il me semble).

Séance 6


DATE : 10/06/2026 --- **Heure :** 16h40 --- **Séance :** 6

Étudiant présent : LACOSTE Nathan BELHARET ADAM

Travail réalisé : collision 64 bits + reverse md5

Nous avons réussi à faire une collision sur 64 bits.

Pour ce faire nous avons modifier le code afin que ce ne soit pas le processeur qui fasse la comparaison mais la carte graphique. Ce qui permet d'augmenter la vitesse significativement.




```
Console de débogage Micros... X + v
Collision MD5 sur 64 bits (table GPU de 2^28 slots)
Hashs testes : 49392123904 | Temps : 220.3 s

COLLISION TROUVEE !
hash = 1240c442abc725ea
msg1 = 110558666
msg2 = 49379194452
Temps total : 220.34 secondes

C:\Users\etudiants\source\repos\md5_bruite_force_collision\x64\Debug\md5_bruite_force_collision.exe (processus 20756) s'
est terminé avec le code 0 (0x0).
Appuyez sur une touche pour fermer cette fenêtre. . .
```

Nous avons aussi réussi à retrouver un mot de passe à partir de son hach md5 grâce à un dictionnaire provenant d'une fuite de donnée de 2009.



```
Console de débogage Micros... X + v
Hash cible : ae43792485331fa311a50a7972118adc
Dictionnaire : C:/Users/etudiants/Desktop/rockyou.txt

TROUVE : hello95
Tentatives : 262144

C:\Users\etudiants\source\repos\Reverse MD5\x64\Release\Reverse MD5.exe (processus 16500) s'est terminé avec le code 0 (
0x0).
Appuyez sur une touche pour fermer cette fenêtre. . .|
```

Séance 7

DATE : 12/06/2026 --- **Heure :** 17h35 --- **Séance :** 7


Étudiant présent : LACOSTE Nathan BELHARET ADAM

Travail réalisé : collision par préfixes md5 + reverse md5 ?

Afin d'optimiser les recherches et l'avancement du projet, nous avons décidés de travailler sur 2 codes en même temps. Adam s'occupait du reverse md5 et moi je m'occupe de la collision par préfixe.

Pour le reverse Adam à trouver un code qui permet de retrouver le type de fichiers en fonction de leur hash grâce à une base de données. Virus Total, NIST NSRL MalwareBazaar, ect. Le seule problème étant que ce genre de base de données sont très grosses donc mettent longtemps à être télécharger. Nous avons donc preferer remettre les téléchargements à la séance suivante.

Quant à moi, j'ai tenté de trouver un code permettant de faire une collision par préfixes. Cependant ce genre de code étant utilisable pour une véritable attaque ou falsification de certificat de sécurité numérique il est très difficile de trouver ce genre de code. Que ce soit sur internet ou en demandant au ia. Finalement j'ai réussi à avoir un code qui me permettrait de faire cette attaque sur 52 bits max. Or lorsque que j'ai vérifier le code, il était pour une attaque sur sha-256.



```
// prefix_collision_cuda.cu
// IMPORTANT : ceci n'est PAS une attaque MD5 réelle. C'est une démo sur hash tronqué.
// Limite volontaire : bits <= 52, préfixe + suffixe <= 55 octets (SHA-256 en 1 bloc).
```


Séance 8


DATE : 17/06/2026 --- **Heure :** 17h58 --- **Séance :** 8

Étudiant présent : LACOSTE Nathan BELHARET ADAM

Travail réalisé : téléchargement et présentation

Durant cette séance, Adam a commencé à travailler sur le diaporama pendant que je m'occuper du code qu'il avait trouvé à la séance précédente.

17,4 Go. C'est la taille de la base de données que j'ai téléchargée. Un téléchargement si long qu'il a pris une bonne partie de l'après-midi.



*// Le téléchargement a échoué une première fois, j'ai donc dû le recommencer.
D'où l'heure tardive de la création du fichier.*

Une fois le téléchargement fini, j'ai pu commencer à travailler que le code. Problème, il ne marchait pas

Séance 9

DATE : 18/06/2026 --- **Heure :** 11h44 --- **Séance :** 9

Étudiant présent : LACOSTE Nathan BELHARET ADAM

Travail réalisé : présentation + déception.

Durant cette séance, nous avons continué et fini le powerpoint ainsi que le texte pour l'oral de demain.

Une fois le Powerpoint fini, nous nous sommes concentrés sur le code de la séance précédente.

Puisque qu'il ne marchait toujours pas, nous avons fait quelque recherche. Et nous avons vite compris que ce code n'aurait pas de grande d'utilité car il faudrait utilise le CPU et non le GPU pour effectuer les recherches dans la base de données.

Pour ton cas précis : 17,5 Go, recherche séquentielle complète

Le contexte change tout

Une recherche "scan complet jusqu'à trouver une correspondance" = parcourir potentiellement toute la table ligne par ligne. C'est ce qu'on appelle un **Full Table Scan**.

Verdict : CPU avec un bon index est la meilleure réponse

// Une séance quasi complete de téléchargement pour finalement ce rendre compte que ça marcherait pas. Yes...

// Au moins maintenant on sait que faut faire les recherches AVANT de télécharger des bases de données de plusieurs Go.